CAHIER DE SPÉCIFICATION DÉCISIONNELLE

Projet Data Engineering — HEALTH RETAILERS

Business Intelligence • Data Warehouse • Machine Learning

Conception d’une solution décisionnelle et analytique pour un drugstore en France

1. Présentation de l’entreprise et du projet

Le projet Health Retailers porte sur l’exploitation décisionnelle des données d’un drugstore situé en France. Les données opérationnelles fournies couvrent plusieurs domaines liés à l’activité : produits, ventes, stocks, clients, fournisseurs, transactions et paiements. L’objectif est de transformer ces données en informations fiables pour le pilotage commercial et opérationnel.

La solution visée repose sur une démarche Data Engineering : profilage des sources, nettoyage et transformation, alimentation d’un Data Warehouse, calcul de mesures et KPI, restitution BI et étude d’un cas de Machine Learning. Le cahier suit le principe du guide : partir des décideurs et de leurs besoins, puis relier chaque question à une mesure, des données et une source.

2. Contexte et problématique décisionnelle

Les données nécessaires au pilotage sont réparties entre plusieurs fichiers et domaines. Le besoin est donc de disposer d’une vision historique et cohérente de l’activité afin de répondre à des questions concernant les ventes, les produits, les clients, les stocks et les paiements.

Chaîne de spécification : Décideur → Objectif métier → Question analytique → KPI / mesure → Données nécessaires → Source / attributs → Formule.

3. Décideurs et objectifs métier

Décideur	Objectif métier	Questions principales
Direction générale	Suivre la performance globale	Quel est le CA ? Quelle est son évolution ? Quels produits, marques et périodes contribuent à l’activité ?
Responsable commercial	Analyser les ventes	Quels produits et marques se vendent le plus ? Quelle est l’évolution du CA et des quantités ?
Responsable relation client	Analyser les clients	Quels clients sont actifs ? Quelle est leur fréquence et leur valeur lorsque les données sont fiables ?
Responsable approvisionnement / stock	Piloter les stocks	Quels produits sont en stock faible ou en rupture ? Quels produits ont une faible rotation ? Quelle demande faut-il anticiper ?
Responsable financier / caisse	Suivre les flux de paiement	Quels montants sont encaissés ? Comment se répartissent les moyens de paiement ?

4. Périmètre

4.1 Inclus

• Produits, prix, marques, codes-barres et taxes lorsqu’ils sont exploitables.

• Documents de vente et lignes de documents.

• Transactions et paiements.

• Mouvements de stock et inventaires.

• Clients et fournisseurs.

• Dimensions temporelles et autres dimensions validées à partir des sources.

4.2 Hors périmètre

Les données techniques d’authentification, de sécurité et de gestion des comptes sont exclues de l’analyse métier, sauf justification spécifique.

4.3 Validation

Les clés, relations, cardinalités, granularités, dates et valeurs manquantes seront validées pendant le profilage. Une hypothèse non vérifiée ne sera pas considérée comme un fait du modèle.

5. Inventaire des sources fournies

Les CSV fournis constituent les sources internes principales. Une première cartographie des fichiers identifiés est présentée ci-dessous ; le mapping attribut par attribut sera confirmé lors du profilage.

Domaine	Fichiers identifiés	Rôle analytique
Produits	Produits - 24112025081625 (2).csv ; ProductBrands.csv ; Barcodes.csv	Référentiel produit, marques, codes-barres
Ventes / documents	DocumentsReports.csv ; DocumentTypes.csv ; RelatedDocuments.csv	Documents et analyse des ventes
Stock / inventaire	InventaireItems.csv ; ProductStocks.csv ; StockMovements.csv	Stock, mouvements, inventaires
Clients	Clients - 24112025081756 (3).csv	Analyse clients
Fournisseurs	Fournisseurs - 24112025081816 (2).csv	Analyse fournisseurs / approvisionnement

Domaine	Fichiers identifiés	Rôle analytique
Paiements / transactions	Payment.csv ; Transactions.csv ; TransactionPayments.csv ; CaisseOperations.csv ; PaymentsList.csv	Transactions et paiements
Taxes / prix	taxRates.csv ; Documents.csv ; ProductPrices.csv ; ApplicableTaxes.csv ; ItemTaxes.csv ; documentItemm.csv	Prix, taxes et lignes de documents
Autres référentiels	users_settings_csv.csv ; CompaniesList.csv ; Permissions.csv ; users_csv.csv ; DomainEvents.csv ; Events.csv	À exploiter uniquement si une question métier le justifie

6. Spécification des besoins décisionnels

6.1 Direction générale — Performance globale

Question	KPI / mesure	Formule	Données
Quel est le CA ?	Chiffre d'affaires	Σ(Quantité × Prix)	Quantité, prix, document/date
Combien de ventes/documents ?	Nombre de documents	COUNT(DISTINCT identifiant)	Identifiant document
Comment évolue le CA ?	Taux de croissance	((CA_N – CA_N-1) / CA_N-1) × 100	CA, date
Quelle période génère le plus de CA ?	CA par période	Σ CA par période	CA, date

6.2 Responsable commercial — Analyse des ventes

Question	KPI / mesure	Formule	Données
Quels produits sont les plus vendus ?	Quantité vendue	Σ Quantité	Produit, quantité
Quels produits génèrent le plus de CA ?	CA par produit	Σ(Quantité × Prix)	Produit, quantité, prix
Quelles marques contribuent le plus ?	CA / quantité par marque	Agrégation par marque	Produit, marque, ventes
Quelle est la valeur moyenne d'une vente ?	Panier moyen	CA / Nb documents	CA, document
Quelle est l'évolution des ventes ?	CA par période	Σ(Quantité × Prix)	Quantité, prix, date

6.3 Responsable relation client — Analyse des clients

Question	KPI / mesure	Formule	Données
Quels clients génèrent le plus de CA ?	CA par client	Σ(Quantité × Prix) par client	Client, ventes
Combien de ventes un client réalise-t-il ?	Fréquence d'achat	COUNT(DISTINCT document)	Client, document
Quelle est sa valeur moyenne ?	Panier moyen client	CA client / Nb documents client	Client, CA, documents
Quels clients sont actifs ?	Clients actifs	Au moins une transaction sur la période	Client, date, transaction

6.4 Responsable approvisionnement / stock — Gestion des stocks

Question	KPI / mesure	Formule / principe	Données
Quels produits ont un stock faible ?	Stock disponible	Stock actuel	Produit, stock
Quels produits sont en rupture ?	Produits en rupture	COUNT(produit où stock = 0)	Produit, stock
Quels produits ont une faible rotation ?	Rotation	À définir après validation de l'historique	Ventes, stock, période
Quelle quantité faut-il prévoir ?	Prévision de demande	Quantité future prédite	Historique ventes + variables X

6.5 Responsable financier / caisse — Paiements

Question	Mesure	Formule	Données
Quel montant est encaissé ?	Montant des paiements	Σ montant	Paiement, transaction
Comment se répartissent les moyens ?	Montant par moyen	Σ montant GROUP BY moyen	Montant, moyen
Comment évoluent les paiements ?	Montant par période	Σ montant par date	Montant, date

7. Données nécessaires et qualité

Domaine	Données recherchées	Utilisation
Produits	Identifiant, libellé, marque, prix, code-barres, taxe si disponible	Dimension produit, ventes, CA
Ventes / documents	Identifiant, date, statut si disponible	Analyse temporelle et documents
Lignes de vente	Document, produit, quantité, prix si disponible	CA et quantités
Stocks	Produit, quantité, mouvement, date si disponible	Stock, ruptures, rotation
Clients	Identifiant et attributs disponibles	Fréquence, valeur, activité
Fournisseurs	Identifiant et attributs disponibles	Approvisionnement si exploitable
Paiements / transactions	Identifiant, montant, moyen, date	Analyse des paiements

7.1 Contrôles de qualité

• Valeurs manquantes et valeurs aberrantes.

• Doublons et unicité des clés.

• Cohérence des types et formats de dates.

• Intégrité référentielle entre documents, lignes et produits.

• Quantités ou montants impossibles / incohérents.

• Granularité réelle de chaque fichier.

• Dates réellement exploitables pour l'analyse temporelle.

8. Données externes

Les données externes sont autorisées lorsqu'elles répondent à une question métier.

Donnée externe	Question / justification	Liaison
Calendrier français	Jours fériés, saisons et jours de semaine pouvant expliquer des variations de demande.	Date
Météo	Température et précipitations comme variables explicatives potentielles.	Date + zone géographique, si fiable

Condition : la météo reste une hypothèse. Elle ne sera intégrée que si la donnée interne possède une granularité géographique compatible et un historique temporel suffisant.

9. Dimensions et mesures pressenties

Élément	Attributs / mesures candidates
Dimension Temps	Jour, semaine, mois, trimestre, année, saison, jour férié
Dimension Produit	Identifiant, libellé, marque, catégorie si disponible, prix, code-barres
Dimension Client	Identifiant et attributs disponibles
Dimension Fournisseur	Identifiant et attributs disponibles
Dimension Paiement	Moyen / type de paiement
Dimension Document	Type / statut si disponible
Dimension Géographie	Zone / ville / région si disponible
Mesures ventes	Quantité vendue, CA, nombre de documents, panier moyen
Mesures stock	Stock disponible, mouvements, inventaires, rotation
Mesures paiements	Montant payé, nombre de transactions

9.1 Granularité candidate

Pour les ventes, la granularité candidate est : **une ligne de produit vendue dans un document à une date donnée**. Cette granularité doit être confirmée à partir des CSV. Pour le stock, la granularité dépendra de la présence d'un historique par produit et par date.

10. Besoins BI / Reporting

Dashboard	Contenu attendu
Synthèse	CA, nombre de ventes/documents, panier moyen et évolution.
Commercial	CA et quantités par produit, marque et période.
Stock	Stock, mouvements, inventaires, faible rotation, ruptures et risques.
Clients	Clients actifs, fréquence et valeur lorsque fiable.
Paiements	Montants par moyen de paiement et évolution.

Filtres minimum : période, produit et marque. D'autres filtres seront ajoutés si les dimensions correspondantes sont validées.

11. Besoin Machine Learning / IA

Le projet retient les quatre objectifs Machine Learning / IA suivants. Chacun est détaillé ensuite dans son propre tableau (variable cible Y, variables explicatives X, type de problème, données, résultat attendu).

N°	Objectif	Type de problème	Résultat attendu
11.1	Prévision de la demande	Régression / séries temporelles	Quantité prévisionnelle par famille/marque et par semaine
11.2	Détection d'anomalies sur les ventes	Détection d'outliers / classification non supervisée	Liste des lignes de vente à contrôler en priorité
11.3	Détection des écarts de caisse et annulations anormales	Détection d'anomalies	Alerte sur les comportements de caisse à risque
11.4	Segmentation client	Clustering	Groupes de clients homogènes pour cibler les actions marketing

11.1 Prévision de la demande

Élément	Exemple
Variable cible Y	Quantité vendue d'une famille/marque sur une période future (semaine)
Variables explicatives X	Historique des ventes, prix, remise, canal (comptoir/facturé), jours fériés, vacances scolaires, indicateurs épidémiques, météo
Type de problème	Régression / séries temporelles
Données internes	`documentItemm`, `Documents`, `Produits`, `ProductStocks` (historique des ventes sur 7 mois)
Données externes	Calendrier, indicateurs épidémiques, Google Trends, météo (secondaire), taux de change EUR/TND
Résultat attendu	Quantité prévisionnelle par famille/marque et par semaine

11.2 Détection d'anomalies sur les ventes

Élément	Exemple
Variable cible Y	Ligne de vente anormale (oui/non)
Variables explicatives X	DiscountPourcentage, écart entre PrixTotalHt et CoûtMoyenPondéré, Quantity, utilisateur, heure
Type de problème	Détection d'outliers / classification non supervisée
Données internes	`documentItemm` (789 lignes à remise > 50%, 22% des lignes vendues sous le coût)
Données externes	Aucune
Résultat attendu	Liste des lignes de vente à contrôler en priorité

11.3 Détection des écarts de caisse et annulations anormales

Élément	Exemple
Variable cible Y	Opération de caisse anormale (oui/non)
Variables explicatives X	Montant, utilisateur, heure, fréquence d'annulation par utilisateur
Type de problème	Détection d'anomalies
Données internes	`DomainEvents` (437 écarts de caisse, 102 annulations déjà enregistrés)
Données externes	Aucune
Résultat attendu	Alerte sur les comportements de caisse à risque

11.4 Segmentation client

Élément	Exemple
Variable cible Y	Aucune (apprentissage non supervisé, pas de cible)
Variables explicatives X	CA total, fréquence d'achat, panier moyen, ancienneté, type de client (B2B/particulier)
Type de problème	Clustering
Données internes	`CompaniesList`, `Documents`, `documentItemm` (limité aux clients identifiés, ~60% du CA)
Données externes	Aucune
Résultat attendu	Groupes de clients homogènes pour cibler les actions marketing

12. KPI : mesures et seuils

Une mesure quantifie un phénomène ; un KPI relie une mesure à un objectif ou un seuil. Aucun seuil métier fictif n'est imposé : les seuils doivent être définis à partir d'objectifs réels ou de règles validées.

KPI candidat	Mesure	Règle / seuil
CA mensuel	CA = Σ(Quantité × Prix)	Seuil à définir
Croissance du CA	((CA_N−CA_N-1)/CA_N-1)×100	Objectif à définir
Taux de rupture	Produits en rupture / produits suivis × 100	Seuil à définir
Panier moyen	CA / Nb documents	Suivi de l'évolution
Erreur de prévision	MAE / RMSE	Comparer au baseline

13. Contraintes et règles de validation

• Commencer par les besoins des décideurs et non par les tables.

• Chaque objectif doit être traduit en questions analytiques.

• Chaque question doit conduire à une mesure, un KPI ou une information à analyser.

• Pour chaque mesure, préciser la formule et les données nécessaires.

• Identifier les attributs sources utilisés pour chaque calcul.

• Ne pas ajouter une donnée externe sans justification métier.

• Faire découler les dimensions et mesures du modèle des besoins identifiés.

• Séparer clairement les variables X et la cible Y pour le ML.

14. Résultats attendus et étapes suivantes

• Profilage détaillé des CSV et validation du mapping source → besoin.

• Nettoyage et transformation des données.

• Conception et implémentation du Data Warehouse.

• Développement des processus ETL.

• Calcul des mesures et KPI.

• Développement des dashboards BI.

• Validation de la faisabilité du cas ML et entraînement/évaluation si les données sont suffisantes.

• Documentation et restitution finale.

15. Conclusion

Ce cahier de spécification constitue le lien entre les besoins métier du Health Retailer et la conception technique de la solution. Il définit les décideurs, objectifs, questions analytiques, mesures, données nécessaires, sources, besoins BI et cas d'usage ML. Les éléments encore dépendants du profilage — relations, granularité, météo et faisabilité de la prévision — sont explicitement identifiés comme à valider.

Principe directeur : une donnée n'est intégrée que si elle répond à une question métier, permet de calculer une mesure/KPI ou apporte une valeur démontrable au cas ML.