CAHIER DE SPÉCIFICATION DÉCISIONNELLE

Projet Data Engineering — HEALTH RETAILERS

Business Intelligence • Data Warehouse • Machine Learning

Conception d’une solution décisionnelle et analytique pour un drugstore en France

Version mise à jour après retour enseignant — modèle BI simplifié, étendu aux achats et aux fournisseurs, objectifs ML précisés

1. Présentation de l’entreprise et du projet

Le projet Health Retailers porte sur l’exploitation décisionnelle des données d’un drugstore situé en France. Les données opérationnelles couvrent les produits, les ventes, les stocks, les clients, les fournisseurs, les transactions et les paiements. L’objectif est de transformer ces données en informations fiables pour le pilotage commercial et opérationnel.

Le dépôt du projet recense 29 fichiers CSV et 370 256 enregistrements sur une période principale allant du 30 septembre 2024 au 30 avril 2025. Cette période réelle est prolongée par des données synthétiques générées du 1er mai 2025 au 29 septembre 2026, soit deux ans d’historique au total. Délimitation : toute donnée datée jusqu’au 30 avril 2025 inclus est réelle ; toute donnée datée à partir du 1er mai 2025 est synthétique. Le pipeline Python réalise le nettoyage, la préparation des données, la construction de jeux décisionnels et la préparation des jeux de données Machine Learning.

Le présent cahier décrit le modèle cible après les retours pédagogiques. Le dépôt Git contient encore un modèle décisionnel plus large ; les scripts devront être alignés sur cette version simplifiée une fois les choix validés par l’équipe.

2. Contexte et problématique décisionnelle

Les informations utiles au pilotage sont réparties dans plusieurs fichiers et ne sont pas directement exploitables. Le projet doit donc fournir une vision cohérente des ventes, des clients, du stock actuel et des paiements, tout en préparant des données adaptées aux cas d’usage Machine Learning.

Chaîne de spécification : Décideur → Objectif métier → Question analytique → Mesure / KPI → Variables nécessaires → Source / attributs → Formule.

Principe retenu : une mesure est définie une seule fois. Les analyses « par produit », « par marque », « par client » ou « par période » sont obtenues dans Power BI par les dimensions, filtres et axes de visualisation, et non par la création de mesures dupliquées.

3. Décideurs et objectifs métier

Décideur	Objectif métier	Questions principales
Direction générale	Suivre la performance globale	Quel est le CA ? Combien de ventes sont réalisées ? Comment évolue l’activité ?
Responsable commercial	Analyser les ventes	Quels produits, familles et marques se vendent le plus ? Quelle est la quantité vendue et le panier moyen ? Quels produits, familles et marques sont les plus rentables ?
Responsable relation client	Analyser les clients	Quels clients identifiés sont actifs ? Quelle est leur fréquence d’achat et leur valeur ?
Responsable approvisionnement / stock	Piloter le stock	Quels produits sont disponibles, en stock faible ou en rupture ? Quelle demande faut-il anticiper ?
Responsable financier / caisse	Suivre les flux de paiement	Quel montant est encaissé ? Quels moyens de paiement sont utilisés ? Comment évoluent les encaissements ? Combien chaque client a-t-il payé ? Combien a-t-on payé à chaque fournisseur ? Quelle vente ou quelle facture chaque paiement règle-t-il ?
Responsable achats	Piloter les achats et les fournisseurs	Combien achète-t-on à chaque fournisseur ? Quels produits, familles et marques sont achetés ? Quel produit vient de quel fournisseur ?

4. Périmètre

4.1 Inclus

- Produits, familles, marques, prix et seuils de stock lorsque les attributs sont fiables.
- Documents de vente et lignes de vente nécessaires au calcul des mesures commerciales.
- Clients identifiés et attributs disponibles pour l’analyse client.
- Stock actuel par produit à une date de référence.
- Paiements, montants et moyens de paiement, avec le client qui paie ou le fournisseur payé.
- Fournisseurs et lignes d’achat des factures et avoirs fournisseurs.
- Dimension temporelle et calendrier français.
- Jeux de données ML pour la prévision de demande, les anomalies de ventes, les anomalies de caisse et la segmentation client.

4.2 Hors périmètre BI actuel

- Analyse détaillée des mouvements de stock comme table de faits BI.
- Analyse géographique ou par utilisateur tant qu’aucun objectif BI ne la justifie.
- Données techniques d’authentification, permissions et sécurité.
- Météo et indicateurs épidémiques comme dimensions BI : ils sont réservés au cas ML de prévision de la demande.

4.3 Validation

Les clés, granularités, types de données, dates et règles de qualité doivent être confirmés à partir des sources. Une table ou une variable n’est conservée dans le modèle final que si elle répond à un objectif métier, permet de calculer une mesure ou apporte une valeur démontrable à un cas ML.

5. Inventaire des sources fournies

Les fichiers du dépôt constituent les sources internes principales. Certains domaines restent disponibles pour les contrôles ETL ou le ML même lorsqu'ils ne deviennent pas une dimension ou une table de faits du Data Warehouse BI final.

Domaine	Fichiers identifiés / exemples	Utilisation retenue
Produits	Produits - 24112025081625 (2).csv ; ProductBrands.csv ; Barcodes.csv ; ProductPrices.csv	Référentiel produit, famille, marque, prix, seuils et liaison avec ventes/stock.
Ventes / documents	Documents.csv ; DocumentsReports.csv ; documentItemm.csv ; DocumentTypes.csv ; RelatedDocuments.csv	Construction de fait_ventes, Document_Id, dates, quantités, montants et contrôle du double comptage.
Stock	ProductStocks.csv ; StockMovements.csv ; InventaireItems.csv	ProductStocks alimente le stock actuel. Les mouvements restent disponibles en source/ETL si un calcul historique est nécessaire.
Clients	Clients - 24112025081756 (3).csv ; CompaniesList.csv ; Transactions.csv	Construction de dim_client et analyses limitées aux clients identifiés.
Fournisseurs / achats	Fournisseurs - 24112025081816 (2).csv ; CompaniesList.csv ; Documents.csv et documentItemm.csv (factures et avoirs fournisseurs)	Construction de dim_fournisseur et fait_achats.
Paiements / caisse	Payment.csv ; TransactionPayments.csv ; PaymentsList.csv ; CaisseOperations.csv ; TresoreriePayments.csv	Construction de fait_encaissements (paiements des clients) et fait_decaissements (paiements aux fournisseurs), et préparation du cas ML caisse.
Autres référentiels	users_csv.csv ; DomainEvents.csv ; Events.csv ; Permissions.csv	À utiliser uniquement pour ETL ou ML lorsqu'une question métier le justifie.

6. Spécification des besoins décisionnels BI

Les mesures ci-dessous sont les mesures de base du modèle BI. Elles ne sont pas répétées sous des noms différents selon l'axe d'analyse. Power BI applique les dimensions et filtres pour obtenir les vues par produit, marque, client, période ou moyen de paiement.

Mesure de base	Formule / règle	Variables nécessaires	Dimensions / filtres possibles
Chiffre d'affaires HT	SUM(CA_HT)	CA_HT	Temps, produit, famille, marque, client
Quantité vendue	SUM(QuantiteVendue)	QuantiteVendue	Temps, produit, famille, marque
Nombre de ventes	COUNT(DISTINCT Document_Id)	Document_Id	Temps, client
Panier moyen	CA_HT / Nombre de ventes	CA_HT, Document_Id	Temps, client
Taux de croissance du CA	(CA_N - CA_N-1) / CA_N-1 × 100	CA_HT, DateKey	Temps
Marge HT	SUM(CA_HT) - SUM(Cout_HT)	CA_HT, Cout_HT	Temps, produit, famille, marque
Clients actifs	DISTINCTCOUNT(Company_Id) avec au moins une vente sur la période	Company_Id, DateKey	Temps, type client
Stock disponible	Quantity	Product_Id, Quantity	Produit, famille, marque
Produits en rupture	COUNT(Product_Id) où Quantity = 0	Product_Id, Quantity	Produit, famille, marque
Produits en stock faible	COUNT(Product_Id) où 0 < Quantity <= QuantiteAlerte (fait_stock_actuel)	Product_Id, Quantity, QuantiteAlerte	Produit, famille, marque
Montant encaissé	SUM(Amount) sur fait_encaissements	Amount	Temps, moyen de paiement, client
Montant payé aux fournisseurs	SUM(Amount) sur fait_decaissements	Amount	Temps, moyen de paiement, fournisseur
Nombre de paiements	DISTINCTCOUNT(Payment_Id)	Payment_Id	Temps, moyen de paiement, client, fournisseur
Montant réglé d'un document	SUM(Amount) par Document_Id	Amount, Document_Id	Vente (fait_ventes) ou facture fournisseur (fait_achats)
Achats HT	SUM(MontantAchat_HT)	MontantAchat_HT	Temps, fournisseur, produit, famille, marque
Quantité achetée	SUM(QuantiteAchetee)	QuantiteAchetee	Temps, fournisseur, produit
Nombre de factures fournisseurs	COUNT(DISTINCT Document_Id) sur fait_achats	Document_Id	Temps, fournisseur

6.1 Direction générale — Performance globale

Élément	Détail
Objectif BI	Suivre la performance globale du drugstore avec un nombre limité de mesures réutilisables.
Questions analytiques	Quel est le CA ? Combien de ventes sont réalisées ? Quel est le panier moyen ? Comment évolue l'activité dans le temps ?
Mesures de base	CA HT ; Nombre de ventes ; Panier moyen ; Taux de croissance du CA.
Variables minimales	CA_HT ; Document_Id ; DateKey.
Dimensions / filtres	dim_temps. Les vues mensuelles, trimestrielles ou annuelles sont obtenues par filtre et non par création de nouvelles mesures.
Résultat attendu	Vue synthétique de la performance globale et de son évolution temporelle.

6.2 Responsable commercial — Analyse des ventes

Élément	Détail
Objectif BI	Analyser les ventes et identifier les produits, familles ou marques qui contribuent le plus à l'activité.
Questions analytiques	Quels produits se vendent le plus ? Quelles familles ou marques contribuent le plus ? Quel est le panier moyen ? Comment évoluent les ventes ? Quels produits, familles ou marques sont les plus rentables ?
Mesures de base	CA HT ; Quantité vendue ; Panier moyen ; Marge HT.
Variables minimales	CA_HT ; Cout_HT ; QuantiteVendue ; Document_Id ; Product_Id ; DateKey.
Dimensions / filtres	dim_produit (produit, famille, marque) et dim_temps. Le même CA et la même quantité sont réutilisés avec différents axes Power BI.
Résultat attendu	Comparaison des performances commerciales par produit, famille, marque et période.

6.3 Responsable relation client — Analyse des clients

Élément	Détail
Objectif BI	Mesurer la valeur et l'activité des clients identifiés sans dupliquer les mesures commerciales.
Questions analytiques	Quels clients génèrent le plus de valeur ? À quelle fréquence achètent-ils ? Quel est leur panier moyen ? Quels clients sont actifs sur une période ?
Mesures de base	CA HT ; Nombre de ventes ; Panier moyen ; Nombre de clients actifs.
Variables minimales	Company_Id ; CA_HT ; Document_Id ; DateKey.
Dimensions / filtres	dim_client et dim_temps. Le CA ou le panier sont les mêmes mesures que dans les autres dashboards, filtrées par client.
Résultat attendu	Analyse des clients identifiés selon leur activité, leur fréquence et leur valeur.
Limite	Les transactions anonymes ne sont pas utilisées pour les KPI nécessitant l'identification d'un client.

6.4 Responsable approvisionnement / stock — Gestion du stock

Élément	Détail
Objectif BI	Connaître l'état actuel du stock et identifier rapidement les produits nécessitant une action.
Questions analytiques	Quel est le stock disponible ? Quels produits sont en rupture ? Quels produits ont un stock inférieur au seuil d'alerte ?
Mesures de base	Stock disponible ; Nombre de produits en rupture ; Nombre de produits en stock faible.
Variables minimales	Product_Id ; Quantity ; QuantiteAlerte ; DateKey.
Dimensions / filtres	dim_produit. Les vues par produit, famille ou marque sont des filtres sur les mêmes indicateurs. Le seuil d'alerte est stocké dans fait_stock_actuel, à côté de la quantité.
Résultat attendu	État du stock actuel et liste des produits en rupture ou en stock faible.
Limite	La rotation historique n'est pas retenue dans le BI actuel tant qu'un historique de stock fiable n'est pas validé. La prévision de demande relève du ML.

6.5 Responsable financier / caisse — Paiements

Élément	Détail
Objectif BI	Suivre les encaissements, les paiements fournisseurs et leur répartition sans créer une mesure différente pour chaque moyen, client, fournisseur ou période.
Questions analytiques	Quel montant est encaissé ? Combien de paiements sont enregistrés ? Comment se répartissent-ils par moyen ? Comment évoluent-ils dans le temps ? Combien chaque client a-t-il payé ? Combien a-t-on payé à chaque fournisseur ? Quelle vente ou quelle facture fournisseur ce paiement règle-t-il ? Combien a été réglé sur chaque document ?
Mesures de base	Montant encaissé ; Montant payé aux fournisseurs ; Nombre de paiements ; Montant réglé d'un document.
Variables minimales	Encaissements : Payment_Id ; Document_Id ; Amount ; PaymentMode_Id ; Company_Id ; DateKey. Décaissements : Payment_Id ; Document_Id ; Amount ; PaymentMode_Id ; Fournisseur_Id ; DateKey.
Dimensions / filtres	dim_paiement, dim_client, dim_fournisseur et dim_temps. Les analyses par carte, espèces, client, fournisseur ou période utilisent les mêmes mesures avec filtres.
Résultat attendu	Suivi des encaissements par période, moyen de paiement et client ; suivi des paiements par fournisseur.
Précaution	La source mélange encaissements clients et paiements fournisseurs dans un même fichier : l'ETL les sépare en deux tables de faits, fait_encaissements (le client paie la pharmacie) et fait_decaissements (la pharmacie paie un fournisseur). Le sens du paiement est donc donné par la table, sans indicateur. Les paiements au comptoir sont rattachés au client comptoir anonyme. Les paiements (TTC) ne se comparent pas directement au CA ou aux achats (HT). Un paiement qui règle plusieurs documents est réparti sur plusieurs lignes (imputation de la source, au prorata du total TTC quand une facture regroupe des bons de livraison).
Limites	L'argent rendu lors d'un retour n'est pas enregistré comme paiement dans la source : les retours apparaissent en négatif dans les ventes et les achats, pas dans les paiements. Le moyen de paiement n'est saisi par le logiciel que pendant les premières semaines (septembre-octobre 2024) : la répartition par moyen n'est représentative que sur cette période.

6.6 Responsable achats — Achats et fournisseurs

Élément	Détail
Objectif BI	Suivre les achats par fournisseur et par produit, et savoir chez quel fournisseur chaque produit est acheté.
Questions analytiques	Combien achète-t-on à chaque fournisseur ? Quels produits, familles et marques sont achetés ? Quel produit vient de quel fournisseur ? Comment évoluent les achats ? Combien a-t-on payé à chaque fournisseur ?
Mesures de base	Achats HT ; Quantité achetée ; Nombre de factures fournisseurs ; Montant payé aux fournisseurs.
Variables minimales	MontantAchat_HT ; QuantiteAchetee ; Document_Id ; Product_Id ; Fournisseur_Id ; DateKey.
Dimensions / filtres	dim_fournisseur, dim_produit et dim_temps. Un même produit pouvant venir de plusieurs fournisseurs, le lien produit → fournisseur passe par fait_achats et non par dim_produit.
Résultat attendu	Comparaison des achats par fournisseur, produit, famille, marque et période.
Limite	Seules les factures et avoirs fournisseurs validés sont chargés (avoirs en négatif). Les achats sont HT et les paiements TTC : le solde dû à un fournisseur n'est pas calculé.

6.7 Synthèse d'utilisation par décideur

Décideur	Mesures utilisées	Analyse réalisée avec les dimensions
Direction générale	CA HT, nombre de ventes, panier moyen, croissance	Évolution par jour, mois, trimestre ou année.
Responsable commercial	CA HT, quantité vendue, panier moyen, marge HT	Produit, famille, marque, période.
Responsable relation client	CA HT, nombre de ventes, panier moyen, clients actifs	Client identifié, type client, période.
Responsable stock	Stock disponible, produits en rupture, produits en stock faible	Produit, famille, marque. La prévision de demande relève du ML.
Responsable financier / caisse	Montant encaissé, montant payé aux fournisseurs, nombre de paiements	Période, moyen de paiement, client, fournisseur.
Responsable achats	Achats HT, quantité achetée, nombre de factures fournisseurs	Fournisseur, produit, famille, marque, période.

La rotation du stock n'est pas retenue comme KPI BI dans la version actuelle. Elle nécessite un stock moyen historique fiable. Elle pourra être réintroduite si l'historique est validé et si le responsable stock confirme ce besoin.

7. Données nécessaires et qualité

Domaine	Variables minimales recherchées	Utilisation
Ventes	Document_Id, DateKey, Product_Id, Company_Id, QuantiteVendue, CA_HT, Cout_HT	Mesures commerciales et client.
Produits	Product_Id, Libellé, Famille, Marque	Filtres produit.
Clients	Company_Id, TypeClient et attributs fiables	Analyse des clients identifiés.
Stock	Product_Id, Quantity, QuantiteAlerte, DateKey	Stock actuel, rupture et stock faible.
Paiements	Payment_Id, Document_Id, DateKey, PaymentMode_Id, Company_Id, Fournisseur_Id, Amount	Montant et nombre de paiements, par client ou par fournisseur ; document réglé.
Achats	Document_Id, DateKey, Product_Id, Fournisseur_Id, QuantiteAchetee, MontantAchat_HT	Achats par fournisseur et par produit.
Fournisseurs	Fournisseur_Id, Nom	Filtre et affichage des fournisseurs.
Temps	DateKey, Date, semaine, mois, trimestre, année, EstFerie	Analyse temporelle et filtres.

7.1 Contrôles de qualité

- Valeurs manquantes, aberrantes ou impossibles.
- Doublons et unicité des clés.
- Cohérence des types et formats de dates.
- Intégrité référentielle entre documents, lignes, produits, clients et fournisseurs.
- Traitement des retours / avoirs et prévention du double comptage entre factures et bons de livraison.
- Validation de la granularité réelle de chaque jeu de données.
- Séparation des ventes anonymes des analyses nécessitant un client identifié.

8. Données externes

Les données externes sont intégrées uniquement lorsqu'elles répondent à un besoin précis. Le calendrier français (jours fériés) n'est pas une source externe : il est calculé et intégré à dim_temps, pour le BI et le ML. La météo et les indicateurs épidémiques ne font pas partie du Data Warehouse BI ; ils sont des variables explicatives candidates pour la prévision de demande.

Donnée externe	Utilisation	Justification	Intégration
Météo (Open-Meteo)	ML	Tester si température / précipitations améliorent la prévision de certaines familles saisonnières.	Dataset de prévision uniquement
Indicateurs épidémiques (Réseau Sentinelles)	ML	Tester si le contexte épidémique améliore la prévision de certaines familles de produits de santé.	Dataset de prévision uniquement
Données synthétiques (prolongation du 01/05/2025 au 29/09/2026)	BI + ML	Disposer de deux ans d'historique pour l'évolution temporelle, la saisonnalité et la prévision.	Fichiers séparés, même format que les sources ; délimitation par la date (données réelles jusqu'au 30/04/2025 inclus). Les types de documents rares (avoirs client et fournisseur) ne sont pas générés ; les retours clients y apparaissent comme lignes négatives de tickets de caisse.

Règle de validation : météo et épidémies seront conservées uniquement si leur ajout améliore réellement la performance du modèle par rapport à une version sans ces variables. Elles ne sont pas considérées comme des causes établies a priori.

Cette évaluation est réalisée sur la période réelle uniquement (données datées jusqu'au 30 avril 2025), car des effets météo et épidémiques ont servi d'hypothèses à la génération des données synthétiques.

9. Modèle Data Warehouse cible

Le modèle cible est volontairement réduit aux tables nécessaires aux objectifs BI : 5 dimensions et 5 tables de faits. Il est organisé en deux cycles symétriques : **cycle de vente** (fait_ventes et fait_encaissements, autour de dim_client) et **cycle d'achat** (fait_achats et fait_decaissements, autour de dim_fournisseur), avec le stock actuel et les dimensions communes dim_temps, dim_produit et dim_paiement. Les achats, les fournisseurs et la séparation des paiements répondent aux besoins du responsable achats (§6.6) et du responsable financier (§6.5).

Type	Table	Grain	PK / FK principales	Variables utiles / rôle
Dimension	dim_temps	1 ligne = 1 date (du 30/09/2024 au 29/09/2026)	PK DateKey	Date, semaine, mois, trimestre, année, EstFerie
Dimension	dim_produit	1 ligne = 1 produit	PK Product_Id	Libellé, Famille, Marque
Dimension	dim_client	1 ligne = 1 client, y compris le client comptoir anonyme (filtre EstClientIdentifie pour les KPI clients)	PK Company_Id	TypeClient + attributs fiables
Dimension	dim_fournisseur	1 ligne = 1 fournisseur	PK Fournisseur_Id	Nom (-1 = non renseigné ou sans objet)
Dimension	dim_paiement	1 ligne = 1 moyen de paiement	PK PaymentMode_Id	Libellé / type de moyen
Fait	fait_ventes	1 produit vendu dans 1 document à 1 date	PK Id ; FK DateKey, Product_Id, Company_Id	Document_Id, QuantiteVendue, CA_HT, Remise_HT, Cout_HT
Fait	fait_achats	1 produit acheté dans 1 facture fournisseur à 1 date	PK Id ; FK DateKey, Product_Id, Fournisseur_Id	Document_Id, QuantiteAchetee, MontantAchat_HT (avoirs en négatif)
Fait	fait_stock_actuel	1 produit à la date de snapshot	PK/FK Product_Id ; FK DateKey	Quantity, QuantiteAlerte (seuil d'alerte du produit). Rupture et stock faible sont calculés.
Fait	fait_encaissements	1 encaissement imputé à 1 vente réglée	PK Id ; FK DateKey, PaymentMode_Id, Company_Id	Payment_Id, Document_Id (vente réglée), Amount. Company_Id = client qui paie (2 = comptoir).
Fait	fait_decaissements	1 décaissement imputé à 1 facture fournisseur réglée	PK Id ; FK DateKey, PaymentMode_Id, Fournisseur_Id	Payment_Id, Document_Id (facture fournisseur réglée), Amount.

Document_Id est conservé directement dans fait_ventes pour compter les ventes distinctes et calculer le panier moyen ; la même clé relie un encaissement à sa vente (fait_encaissements → fait_ventes) et un décaissement à sa facture fournisseur (fait_decaissements → fait_achats). Une dimension Document séparée n'est pas nécessaire tant qu'aucun objectif BI n'analyse le type, le statut ou le canal du document.
Les sources StockMovements, utilisateurs et géographie peuvent rester disponibles dans les zones source/ETL ou les datasets ML sans devenir des tables du Data Warehouse BI final.

10. Besoins BI / Reporting

Dashboard	Mesures principales	Filtres / axes
Synthèse	CA HT, nombre de ventes, panier moyen, croissance	Période
Commercial	CA HT, quantité vendue, panier moyen, marge HT	Période, produit, famille, marque
Stock	Stock disponible, produits en rupture, produits en stock faible	Produit, famille, marque
Clients	CA HT, nombre de ventes, panier moyen, clients actifs	Client identifié, type client, période
Paiements	Montant encaissé, montant payé aux fournisseurs, trésorerie nette, nombre de paiements	Période, moyen de paiement, client, fournisseur
Achats	Achats HT, quantité achetée, nombre de factures fournisseurs	Période, fournisseur, produit, famille, marque

Les mêmes mesures de base sont réutilisées dans plusieurs dashboards. La variation de l'analyse est obtenue par les dimensions et filtres Power BI, et non par des mesures redondantes.

11. Besoins Machine Learning / IA

N°	Objectif	Type de problème	Résultat attendu
11.1	Prévision de la demande	Régression / séries temporelles	Quantité prévue pour la semaine N+1 par famille ou par marque.
11.2	Détection d'anomalies sur les ventes	Détection d'outliers non supervisée	Liste de lignes de vente à contrôler.
11.3	Détection d'anomalies de caisse	Anomalies / classification selon le sous-cas	Opérations ou annulations à examiner.
11.4	Segmentation client	Clustering	Groupes de clients homogènes pour l'analyse marketing.

11.1 Prévision de la demande

Élément	Spécification retenue
Objectif métier	Anticiper la demande afin d'aider le responsable stock à préparer l'approvisionnement et limiter les ruptures.
Granularité famille	1 ligne = 1 semaine × 1 famille de produits.
Granularité marque	1 ligne = 1 semaine × 1 marque. Les deux datasets sont préparés séparément.
Horizon	Prévision à N+1 semaine.
Variable cible Y	Quantité totale vendue pendant la semaine suivante pour la famille ou la marque étudiée.
Variables X internes	Quantités des semaines précédentes (lags), moyenne mobile, prix moyen, taux de remise, nombre de documents, canal si exploitable.
Variables X temporelles	Semaine, mois, jour férié.
Variables X externes candidates	Température, précipitations, indicateurs épidémiques ; conservés seulement si leur apport est mesurable.
Évaluation	MAE / RMSE, comparées à une baseline naïve ou moyenne mobile.
Résultat attendu	Prévision hebdomadaire par famille ou par marque, avec limites liées à l'historique disponible.

Le dépôt prépare déjà deux jeux hebdomadaires distincts : un par famille et un par marque. Il ne faut donc pas présenter la granularité comme « semaine × famille × marque ».

11.2 Détection d'anomalies sur les ventes

Élément	Spécification
Objectif	Identifier des ventes inhabituelles nécessitant une vérification humaine.
Variables X	Taux de remise, écart prix / coût, quantité, utilisateur, heure et autres indicateurs disponibles.
Cible Y	Pas de cible fiable si l'approche reste non supervisée. Les règles métier servent à contrôler les résultats, pas à prouver une anomalie.
Méthodes candidates	Isolation Forest, LOF ou méthode non supervisée équivalente.
Résultat attendu	Score / liste de lignes de vente à contrôler en priorité.

11.3 Détection d'anomalies de caisse

Élément	Spécification
Objectif	Identifier les opérations de caisse inhabituelles et les annulations à examiner.
Variables X	Montant, utilisateur, heure, fréquence d'annulation et variables disponibles dans les événements de caisse.
Y possible	IsCancelled si le sous-problème retenu est une classification d'annulation.
Précaution	Une opération annulée ou atypique n'est pas automatiquement frauduleuse. Une validation humaine est nécessaire.

11.4 Segmentation client

Élément	Spécification
Objectif	Regrouper les clients identifiés selon leur comportement d'achat.
Type	Clustering non supervisé ; aucune cible Y.
Variables X	CA total, fréquence, panier moyen, récence, ancienneté, nombre de produits distincts, type de client si fiable.
Résultat attendu	Segments interprétables permettant de comparer des profils de clients.

12. KPI, mesures et règles de validation

Mesure / KPI	Formule	Règle essentielle
CA HT	SUM(CA_HT)	Utiliser une définition unique et éviter tout double comptage des documents liés.
Nombre de ventes	COUNT(DISTINCT Document_Id)	Ne pas compter les lignes de vente comme des ventes distinctes.
Panier moyen	CA HT / nombre de ventes	Même mesure réutilisée avec filtres temps/client dans Power BI.
Croissance du CA	(CA_N - CA_N-1) / CA_N-1 × 100	Comparer des périodes cohérentes.
Marge HT	SUM(CA_HT) - SUM(Cout_HT)	Calculée comme mesure, non stockée ; les lignes sans coût sont exclues.
Produits en rupture	COUNT(Product_Id où Quantity = 0)	Basé sur le snapshot de stock retenu.
Stock faible	0 < Quantity <= QuantiteAlerte	Le seuil provient du référentiel produit (ou d'une règle validée) et est stocké dans fait_stock_actuel.
Montant encaissé	SUM(Amount) sur fait_encaissements	Les paiements fournisseurs sont dans une autre table (fait_decaissements) : aucun filtre nécessaire.
Trésorerie nette	Montant encaissé − Montant payé aux fournisseurs	Calculée par mesure à travers dim_temps ; les deux tables de paiements ne sont pas reliées entre elles.
Nombre de paiements	DISTINCTCOUNT(Payment_Id)	Une ligne de fait_encaissements ou de fait_decaissements est une imputation : ne pas compter les lignes comme des paiements.
Achats HT	SUM(MontantAchat_HT)	Factures fournisseurs validées uniquement ; avoirs en négatif.
Erreur de prévision	MAE / RMSE	Évaluer sur une période future non utilisée pour l'entraînement et comparer à une baseline.

13. Méthodologie de travail

1. Comprendre les besoins métier et valider les questions analytiques.
2. Profiler les 29 CSV et documenter la qualité des données.
3. Nettoyer et normaliser les sources sans modifier les fichiers bruts.
4. Construire le modèle BI minimal à partir des mesures et dimensions réellement nécessaires.
5. Charger les données préparées et construire les mesures dans Power BI.
6. Préparer séparément les jeux ML avec variables X, cible Y lorsqu'elle existe, granularité et métriques d'évaluation.
7. Évaluer les données externes et ne conserver que celles qui améliorent réellement le cas ML.
8. Documenter les résultats, limites, hypothèses et règles de gouvernance.

14. Résultats attendus et étapes suivantes

- Alignement du schéma et des scripts Git sur le modèle BI simplifié après validation par l'équipe.
- Construction / chargement des 5 faits et 5 dimensions cibles.
- Développement des six dashboards Power BI avec des mesures réutilisables et des filtres.

- Préparation et entraînement des quatre cas ML selon la disponibilité et la qualité des données.
- Comparaison des modèles de prévision à une baseline et validation de l'apport des variables externes.
- Documentation finale du mapping source → variable → mesure / KPI → dashboard ou cas ML.

15. Règles à retenir

- Commencer par les objectifs métier et non par les tables disponibles.
- Définir une mesure BI une seule fois ; utiliser les dimensions et filtres Power BI pour changer l'axe d'analyse.
- Ne conserver dans le Data Warehouse que les faits et dimensions directement justifiés par les objectifs BI.
- Ne pas transformer une donnée utile au ML en dimension BI si aucun besoin BI ne l'exige.
- Séparer clairement les variables X, la cible Y, la granularité et la métrique d'évaluation de chaque cas ML.
- Ne pas présenter une corrélation supposée comme une causalité : météo et épidémies doivent démontrer leur apport.
- Conserver les sources brutes et les données ETL même lorsqu'elles ne sont pas présentes dans le modèle BI final.
- Documenter les limites : remboursements non enregistrés comme paiements, moyen de paiement saisi seulement en septembre-octobre 2024, historique réel de 7 mois (jusqu'au 30 avril 2025) prolongé à 2 ans par des données synthétiques, clients anonymes, qualité des sources et disponibilité des stocks historiques.

16. Conclusion

Le projet Health Retailers doit fournir une base décisionnelle simple, cohérente et directement reliée aux besoins des responsables. La version cible retient cinq tables de faits — ventes, encaissements, achats, décaissements et stock actuel — et cinq dimensions — temps, produit, client, fournisseur et paiement. Les mesures BI sont centralisées et réutilisées dans Power BI par filtrage plutôt que dupliquées pour chaque axe d'analyse.

Les cas Machine Learning sont traités séparément avec leurs propres variables, granularités et critères d'évaluation. La prévision de demande est définie à la semaine, séparément par famille ou par marque ; la météo et les indicateurs épidémiques restent des variables explicatives candidates, uniquement conservées si leur contribution est démontrée.

Cette organisation respecte le principe directeur du projet : une donnée n'est intégrée au modèle que si elle répond à une question métier, permet de calculer une mesure / KPI ou apporte une valeur démontrable à un cas Machine Learning.