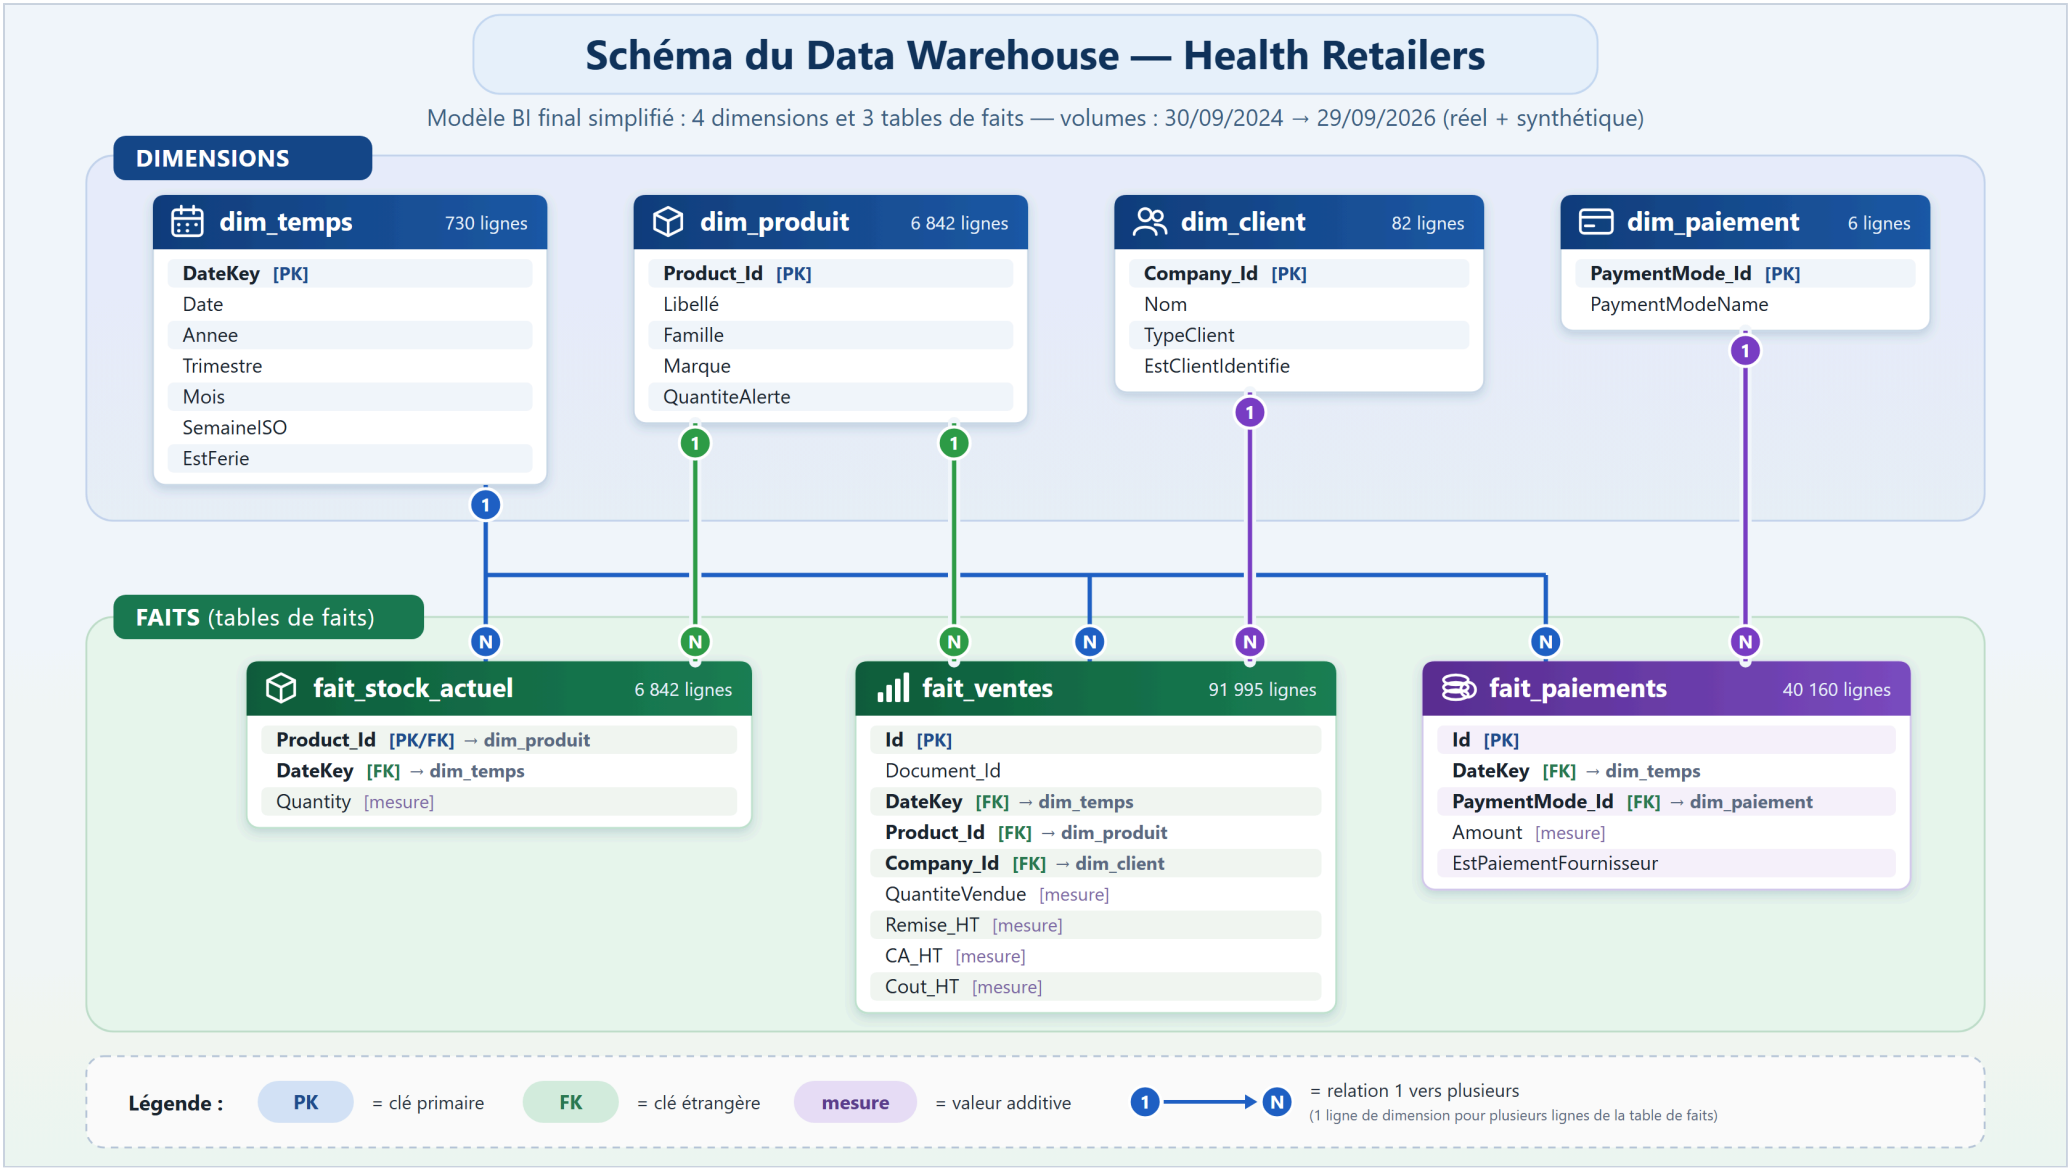
# Schéma du Data Warehouse — Health Retailers

Modèle BI final simplifié (version B) : 4 dimensions et 3 tables de faits — descriptif détaillé




Clés primaires (PK), clés étrangères (FK) et mesures. La couleur d'un lien est celle de la dimension d'origine. Volumes de la période chargée (30/09/2024 → 29/09/2026) : données réelles du 30/09/2024 → 30/04/2025, puis données synthétiques. Le détail de chaque table, des relations et des mesures figure dans les pages suivantes.

## 1. Présentation du modèle

Le Data Warehouse de Health Retailers est un **modèle dimensionnel en constellation** : trois tables de faits partagent des dimensions communes. Chaque table de faits enregistre un processus métier (une vente, l'état du stock, un paiement) au niveau de détail utile au cahier de spécification ; chaque dimension apporte le contexte d'analyse (quand, quoi, qui, comment).

| Élément | Choix retenu |
|---|---|
| Dimensions (4) | `dim_temps`, `dim_produit`, `dim_client`, `dim_paiement` |
| Tables de faits (3) | `fait_ventes`, `fait_stock_actuel`, `fait_paiements` |
| Règle de conservation d'une colonne | Une colonne n'est stockée que si elle est **exigée par le cahier** (KPI, filtre ou attribut cité) **et** qu'elle **ne peut pas être recalculée** à partir des autres colonnes du Data Warehouse. Tout le reste est calculé dans Power BI ou reste en zone ETL. |
| Principe des mesures | Une mesure est définie une seule fois dans Power BI ; les vues par produit, marque, client, période ou moyen de paiement sont obtenues par les dimensions et les filtres. |
| Période | Données réelles du 30/09/2024 → 30/04/2025 (7 mois), prolongées par des données synthétiques jusqu'au 29/09/2026 (2 ans au total). |
| Délimitation réel / synthétique | Par la date, sans colonne dédiée : toute donnée datée jusqu'au 30/04/2025 inclus est réelle ; toute donnée à partir du 01/05/2025 est synthétique. |
| Données externes | Météo (Open-Meteo) et indicateurs épidémiques (Réseau Sentinelles) : réservés au jeu ML de prévision de la demande, **hors du Data Warehouse**. Le calendrier français (jours fériés) est calculé dans `dim_temps`. |
| Machine Learning | Les jeux ML sont construits à partir des données nettoyées (zone ETL), pas à partir du Data Warehouse : retirer une colonne du DW n'enlève rien aux cas ML. |

## 2. Vue d'ensemble des tables

| Table | Type | Grain | Clé primaire | Clés étrangères | Col. | Lignes |
|---|---|---|---|---|---|---|
| `dim_temps` | Dimension | 1 ligne = 1 date | DateKey | — | 7 | 730 |
| `dim_produit` | Dimension | 1 ligne = 1 produit | Product_Id | — | 5 | 6 842 |
| `dim_client` | Dimension | 1 ligne = 1 client, y compris le client comptoir anonyme | Company_Id | — | 4 | 82 |
| `dim_paiement` | Dimension | 1 ligne = 1 moyen de paiement | PaymentMode_Id | — | 2 | 6 |
| `fait_ventes` | Fait | 1 produit vendu dans 1 document à 1 date | Id | DateKey, Product_Id, Company_Id | 9 | 91 995 |
| `fait_stock_actuel` | Fait (snapshot) | 1 produit à la date de snapshot | Product_Id | Product_Id, DateKey | 3 | 6 842 |
| `fait_paiements` | Fait | 1 paiement | Id | DateKey, PaymentMode_Id | 5 | 40 160 |

fait_ventes : 25 743 lignes réelles et 66 252 synthétiques ; fait_paiements : 10 899 réels et 29 261 synthétiques ; fait_stock_actuel : photo au 29/09/2026.

## 3. Relations

Toutes les relations vont d'une dimension (côté 1) vers une table de faits (côté N).

| Dimension (1) | Table de faits (N) | Clé de jointure | Utilisation |
|---|---|---|---|
| `dim_temps` | `fait_ventes` | DateKey | Évolution du CA, des ventes, du panier ; croissance |
| `dim_temps` | `fait_stock_actuel` | DateKey | Date du snapshot de stock |
| `dim_temps` | `fait_paiements` | DateKey | Évolution des encaissements |
| `dim_produit` | `fait_ventes` | Product_Id | Ventes et marge par produit, famille, marque |
| `dim_produit` | `fait_stock_actuel` | Product_Id | Stock disponible, ruptures, stock faible par produit, famille, marque |
| `dim_client` | `fait_ventes` | Company_Id | Analyse des clients identifiés, clients actifs |
| `dim_paiement` | `fait_paiements` | PaymentMode_Id | Répartition des encaissements par moyen de paiement |

> Les tables de faits ne sont **pas reliées entre elles** : une analyse croisée (par exemple ventes et stock d'un même produit) passe par la dimension commune, ici `dim_produit`.

## 4. Dictionnaire des données

Légende : **PK** clé primaire · **FK** clé étrangère · **mesure** valeur additive.

### dim_temps DIMENSION

| Colonne | Rôle | Description |
|---|---|---|
| DateKey | **PK** | Clé de la date au format AAAAMMJJ (ex. 20250430). |
| Date | attribut | Date calendaire. |
| Annee | attribut | Année civile. |
| Trimestre | attribut | Trimestre (1 à 4) ; vues trimestrielles de la direction (§6.1). |
| Mois | attribut | Numéro du mois (1 à 12). |
| SemaineISO | attribut | Numéro de semaine ISO 8601 (granularité de la prévision ML). |
| EstFerie | attribut | Jour férié français (fêtes fixes et fêtes mobiles calculées à partir de Pâques). Remplace une source externe de calendrier. |

### dim_produit DIMENSION

| Colonne | Rôle | Description |
|---|---|---|
| Product_Id | **PK** | Identifiant numérique du produit dans le logiciel (référentiel ProductStocks). |
| Libellé | attribut | Nom du produit (export Produits, sinon dernier libellé connu dans les événements ou les lignes de vente). |
| Famille | attribut | Catégorie du produit ; NON RENSEIGNE si inconnue. |
| Marque | attribut | Marque (export Produits, ou déduite du début du libellé) ; NON RENSEIGNE si inconnue. |
| QuantiteAlerte | attribut | Seuil d'alerte de stock choisi par le magasin (export Produits, sinon paramètre par défaut du logiciel = 5). Non calculable : c'est un paramètre, pas une mesure du stock. |

> Seuils d'alerte les plus fréquents : 5 (3 868 produits), 1 (2 970 produits).

### dim_client DIMENSION

| Colonne | Rôle | Description |
|---|---|---|
| Company_Id | **PK** | Identifiant de la société dans le logiciel (CompaniesList) ; -1 = client non renseigné. |
| Nom | attribut | Nom du client, pour l'affichage dans le dashboard Clients. |
| TypeClient | attribut | PARTICULIER, B2B (laboratoires), COMPTOIR_ANONYME (client de passage, Company_Id = 2) ou NON RENSEIGNE. Axe « type client » du cahier (§6, §10). |
| EstClientIdentifie | attribut | false pour le client comptoir anonyme et la ligne -1 : filtre de tous les KPI clients. Gardé bien que théoriquement déductible : il porte une règle métier (quels clients sont anonymes), définie une seule fois. |

> Types : NON RENSEIGNE (34), PARTICULIER (29), B2B (18), COMPTOIR_ANONYME (1).

### dim_paiement DIMENSION

| Colonne | Rôle | Description |
|---|---|---|
| PaymentMode_Id | **PK** | Identifiant du moyen de paiement : 11 Espèces, 5 Carte bancaire, 1 Chèque, 7 Crédit (paiement différé), 21 Jetons, -1 Non renseigné. |
| PaymentModeName | attribut | Libellé affiché dans les graphiques et les filtres du dashboard Paiements (§9 : « Libellé / type de moyen »). |

### fait_ventes FAIT

| Colonne | Rôle | Description |
|---|---|---|
| Id | **PK** | Identifiant de la ligne de document source. |
| Document_Id | dimension dégénérée | Identifiant du document (ticket, bon de livraison, facture) : permet de compter les ventes et de calculer le panier moyen, sans dimension Document. |
| DateKey | **FK** → dim_temps | Date du document. |
| Product_Id | **FK** → dim_produit | Produit vendu. |
| Company_Id | **FK** → dim_client | Client de la transaction ; -1 si non renseigné. |
| QuantiteVendue | **mesure** | Quantité vendue, négative pour un retour ou un avoir. |
| Remise_HT | **mesure** | Montant total de la remise HT accordée sur la ligne (cité par le cahier, §9). |
| CA_HT | **mesure** | Chiffre d'affaires HT de la ligne, remises déduites, signé (négatif pour un retour). |
| Cout_HT | **mesure** | Coût d'achat HT = quantité × coût unitaire à la date de la vente (coût moyen pondéré du mouvement de stock, à défaut prix d'achat du produit), calculé dans l'ETL. Vide si aucun coût n'est connu. |

> **Exemple réel — Document_Id 15 (ticket VC0013/24) :** 3 lignes, CA HT = 86,05 + 34,96 + 34,96 = 155,97 € ; coût HT = 134,89 € ; marge HT = 21,08 €. Il compte pour **1 vente** (91 995 lignes = 42 540 ventes). Lignes chargées : ventes comptoir, bons de livraison, factures client et retours validés ; brouillons, lignes de commentaire et factures qui regroupent des bons de livraison déjà comptés sont exclus.

### fait_stock_actuel FAIT · SNAPSHOT

| Colonne | Rôle | Description |
|---|---|---|
| Product_Id | **PK** / **FK** → dim_produit | Produit (une ligne par produit). |
| DateKey | **FK** → dim_temps | Date de la photo du stock (fin de la période chargée). |
| Quantity | **mesure** | Quantité en stock selon le logiciel ; peut être négative quand une vente est enregistrée avant ou sans la réception de la marchandise (le logiciel l'autorise pour les ventes comptoir et les bons de livraison). |

> Au snapshot : 1 777 produits à 0, 2 470 en stock faible, 339 à stock négatif. Rupture et stock faible ne sont **pas stockés** : mesures Power BI à partir de `Quantity` et `dim_produit.QuantiteAlerte` (§9).

### fait_paiements FAIT

| Colonne | Rôle | Description |
|---|---|---|
| Id | **PK** | Identifiant du paiement. |
| DateKey | **FK** → dim_temps | Date du paiement. |
| PaymentMode_Id | **FK** → dim_paiement | Moyen de paiement ; -1 si non renseigné. |
| Amount | **mesure** | Montant TTC réellement versé. Valeur de base non recalculable : elle diffère du CA (impayés, paiements fractionnés ou différés, TVA). |
| EstPaiementFournisseur | indicateur | true pour un paiement à un fournisseur. Non déductible du montant (tous les montants sont positifs) ; filtre exigé par le cahier pour le montant encaissé (§6.5, §9, §12). |

> Encaissé clients : 3 026 072 € sur 38 541 paiements ; paiements fournisseurs : 1 619 (1 930 937 €), exclus du montant encaissé. 37 659 paiements clients (98 %) n'ont pas de moyen renseigné dans la source.

## 5. Mesures et KPI (Power BI)

| Mesure / KPI | Formule | Tables | Dashboards |
|---|---|---|---|
| CA HT | `SUM(CA_HT)` | fait_ventes | Synthèse, Commercial, Clients |

| | | | |
|---|---|---|---|
| Quantité vendue | `SUM(QuantiteVendue)` | fait_ventes | Commercial |
| Nombre de ventes | `COUNT(DISTINCT Document_Id)` | fait_ventes | Synthèse, Clients |
| Panier moyen | `CA HT / Nombre de ventes` | fait_ventes | Synthèse, Commercial, Clients |
| Taux de croissance du CA | `(CA_N − CA_N-1) / CA_N-1 × 100` | fait_ventes + dim_temps | Synthèse |
| Marge HT | `SUM(CA_HT) − SUM(Cout_HT), lignes sans coût exclues` | fait_ventes | Commercial |
| Clients actifs | `DISTINCTCOUNT(Company_Id) avec au moins une vente, filtre EstClientIdentifie = true` | fait_ventes + dim_client | Clients |
| Stock disponible | `SUM(Quantity)` | fait_stock_actuel | Stock |
| Produits en rupture | `COUNT(Product_Id) où Quantity = 0` | fait_stock_actuel | Stock |
| Produits en stock faible | `COUNT(Product_Id) où 0 < Quantity ≤ QuantiteAlerte` | fait_stock_actuel + dim_produit | Stock |
| Montant encaissé | `SUM(Amount) où EstPaiementFournisseur = false` | fait_paiements | Paiements |
| Nombre de paiements | `COUNT(Id)` | fait_paiements | Paiements |

## 6. Différences avec le modèle précédent (version A)

| Élément retiré | Raison |
|---|---|
| dim_document | Document_Id est gardé directement dans fait_ventes ; aucun KPI n'analyse le type ou le statut du document. |
| dim_fournisseur, fait_achats | Analyse fournisseur hors périmètre ; les factures fournisseur restent en zone ETL (coût, stock). |
| dim_geographie, dim_utilisateur | Analyses géographique et par utilisateur hors périmètre BI. |
| fait_stock_hebdo, fait_stock_mouvements | Pas d'historique de stock dans le BI ; les mouvements restent en source / ETL. |
| dim_temps : météo, épidémies, vacances, AnneeMois, NomJour, Saison… | Météo et épidémies réservées au ML ; vacances non retenues ; le reste se déduit de la date. |
| dim_produit : codes, prix, TVA, coût moyen pondéré… | Aucun KPI ne les utilise ; prix et coût servent dans l'ETL au calcul de CA_HT et Cout_HT. |
| dim_client : Code, Solde, Ville, Geo_Id | Code = clé de jointure de l'ETL ; aucun KPI n'utilise le solde ni la ville. |
| dim_paiement : EstEspeces, EstDiffere, ligne « Inconnu (4) » | Déductibles du moyen de paiement ; la ligne 4 n'est utilisée par aucun paiement. |
| fait_ventes : CA_TTC, Marge_HT, CoutUnitaire, Signe, taux de remise, colonnes brutes | Recalculables ou non utilisées par les KPI ; la marge devient une mesure. |
| fait_stock_actuel : EnRupture, StockFaible, ValeurStock_HT, rotation, couverture… | Rupture et stock faible deviennent des mesures ; les autres ne sont pas des KPI du cahier. |
| fait_paiements : UsedAmount, client, fournisseur, document, heure, caisse | UsedAmount = Amount à 99,9 % ; aucun KPI n'utilise les autres colonnes. |

## 7. Règles de chargement et limites

- **Valeurs inconnues :** un client ou un moyen de paiement absent pointe vers la ligne -1 « NON RENSEIGNE » de `dim_client` ou `dim_paiement` ; le produit et la date sont toujours renseignés.
- **Documents :** seuls les documents validés sont chargés ; retours et avoirs signés négativement ; pas de double comptage entre factures et bons de livraison.
- **Ventes anonymes :** conservées (client comptoir) mais exclues des KPI clients par `EstClientIdentifie`.
- **Encaissements :** paiements fournisseurs exclus du montant encaissé par `EstPaiementFournisseur`.
- **Stock :** quantité du logiciel conservée, y compris les stocks négatifs (signalés par les contrôles qualité).
- **Données synthétiques :** générées par simulation (hypothèses documentées dans la branche data-external) ; l'apport de la météo et des épidémies se mesure sur la période réelle uniquement.
- **Sources brutes :** jamais modifiées ; le nettoyage produit des copies, puis le chargement du Data Warehouse.